

3 Recol·lecció de dades i mostres

Mètodes empírics 2

07/04/2025

Avui

- Mostres
- Control
- On són les dades?
- Distribucions

Mostres

Què és una mostra? Dóna un exemple

Tipus de mostres

Mostra completa: tota la població d'interès

Mostra representativa/sense biaix: presa de la mostra completa amb un mètode que no depèn de la mostra que s'està prenent

Mostra no representativa/amb biaix: les dades són influenciades pel mètode de presa

Tipus de mostres

Per la pregunta

"És la l-velaritzada (vs. no velaritzada) un fonéma del Català?"

dóna un exemple d'una mostra representativa i una no representativa

Mida de mostra

Per la pregunta







"És la l-velaritzada (vs. no velaritzada) un fonéma del Català?"

quina diferència fa si tinc una mostra de 5 persones o una de 1000?

Mida de mostra ($p = 0.52$)







Assumeix que la probabilitat que una paraula curta sigui usada per a (i) un significat freqüent és 0.52 vs. (ii) un significat menys freqüent.

Què tan gran ha de ser la mostra per detectar aquesta diferència?









Mida de mostra ($p = 0.65$)

Assumeix que la probabilitat que una paraula curta sigui usada per a (i) un significat freqüent és 0.65 vs. (ii) un significat menys freqüent.



Mida de muestra ($p = 0.9$)

Assumeix que la probabilitat que una paraula curta sigui usada per a (i) un significat freqüent és 0.9 vs. (ii) un significat menys freqüent.



- Tant biaix com mida importen
- Però quant importen es respon en funció de la pregunta i l'efecte que esperes, a priori

Control

Estudis pilot

Versió a petita escala de la teva anàlisi

- Comproveu si el pla d'anàlisi és realitzable
- Comprova la qualitat del pla d'anàlisi, però no necessàriament la seva sensibilitat (en funció de la mida de l'efecte)
- Estalvia temps i diners

Simulacions

Versió idealitzada de la teva anàlisi

- Comprova si el pla d'anàlisi (sense recol·lecció) és realitzable
- Comprova la qualitat del pla d'anàlisi i la seva sensibilitat
- Cec a problemes de recol·lecció; només és tan bo com les teves suposicions
- Estalvia (més) temps i diners

On són les dades?

Experimentales

- Laboratori (eye-tracking, fMRI)
- Plataformes online (MTurk, Prolific, Google Forms)
- Recol·lecció "al carrer"
- Dades de previs estudis (SWOW, NoRaRe, SimLex-999, VisualGenome)

Dades no/semi estructurades


- Corpora (Wikipèdia, Twitter)
- Scraping
- Dades de previs estudis (CLICS)
- Models (word embeddings; language models)

Manipulació de dades experimentals amb R

Distribuciones

Què és una distribució?

Distribucio normal (Gaussiana)



$y \sim \text{Normal}(\mu, \sigma)$


$y \sim \text{Normal}(\text{mitja, desv. est.})$

$y \sim \text{Normal}(170, 2)$

Distribucio normal (Gaussiana)

- **Valors possibles:** numeros reals
- **Paràmetres:** mitjana, desviació estàndard
- Comú "a la natura" i epistèmicament lleugera

Distribucio Bernoulli (Binomial)



$y \sim \text{Bernoulli}(p)$


$y \sim \text{Bernoulli}(\text{prob. d'èxit})$

$y \sim \text{Bernoulli}(0.5)$

Distribucio Bernoulli (Binomial)

- **Valors possibles:** 0 o 1
- **Paràmetres:** probabilitat d'èxit (p)
- Comú en experiments i ciències socials

Distribucio Poisson



$y \sim \text{Poisson}(\lambda)$

$y \sim \text{Poisson}(\text{ritme})$

$y \sim \text{Poisson}(170)$

Distribucio Poisson

- **Valors possibles:** numeros naturals + 0
- **Paràmetres:** ritme (expectativa de mitja)
- Comú en ciències socials, quan comptem esdeveniments
- La seva variància és igual al seu ritme/mitjana $\Rightarrow$
la seva desviació estàndard és $\sqrt{\lambda}$

Propera sessió

- Lliurament de "Assignment 2" (08:00 AM 24/04)
-

- **Introducció a la regressió**